ESCUELA DE INGENIERÍA
UCN COQUIMBO

UNIVERSIDAD CATÓLICA DEL NORTE
CHILE

CIENCIA DE DATOS 2026 – 02

Laboratorio 02: Sistema predictivo con Regresión Logística

Docentes:
Merary Carrasco Montecino
Cristhian Rabi Reyes



Problema

En este laboratorio trabajarán con datos reales de transacciones comerciales de H&M, provenientes del conjunto de datos H&M Personalized Fashion Recommendations, que contiene más de 31 millones de registros de compras, junto con información de clientes, productos, precios, categorías y fechas de venta.

A partir de estos datos, cada equipo deberá formular libremente una problemática de investigación relacionada con el comportamiento de compra de los clientes, definir una pregunta y objetivos propios, y aplicar técnicas de regresión logística para desarrollar modelos predictivos. El propósito es abordar un problema de negocio mediante un proceso de minería de datos, poniendo especial énfasis en la comprensión y preparación de la información, la construcción de variables relevantes, el entrenamiento y evaluación de modelos, y la interpretación de los resultados obtenidos.

Dataset

https://www.kaggle.com/competitions/h-and-m-personalized-fashion-recommendations/data

Etapa I

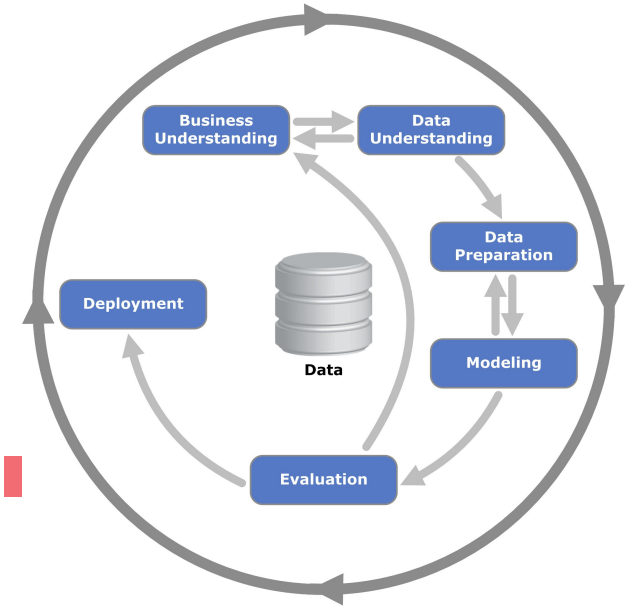
- Explorar el conjunto de datos, identificando la estructura de los archivos, las variables disponibles y las relaciones entre transacciones, clientes y productos, con el propósito de reconocer posibles problemáticas de predicción.
- Definir una pregunta de investigación, un objetivo general y entre 2 y 4 objetivos específicos, orientados a la construcción de un modelo predictivo mediante regresión logística. La propuesta deberá ser presentada al docente para su aprobación antes de continuar con el análisis.
- Definir y justificar la estrategia de construcción del conjunto de datos para el modelado, considerando la unidad de análisis, la variable objetivo, las variables predictoras, la granularidad de las transacciones y las ventanas temporales de observación y predicción. Se deberá prestar especial atención a la correcta separación temporal de la información, evitando incorporar datos futuros que puedan producir fuga de información (data leakage).

Entregable opcional: Un documento simple con la pregunta de investigación, objetivo general, objetivos específicos y describir brevemente cómo construirá el conjunto de datos para modelado.

Etapa II

- Desarrollar un análisis exploratorio de datos (EDA) que incluya limpieza, visualización y transformación de los datos, identificando patrones, distribuciones y relaciones relevantes.
- Identificar y tratar adecuadamente datos faltantes, duplicados, inconsistencias y valores atípicos, justificando las decisiones adoptadas.
- Construir el conjunto de datos para el modelado, considerando la agregación de transacciones, las ventanas temporales y la prevención de fuga de información (data leakage).
- Implementar y comparar modelos de regresión logística, utilizando estrategias de entrenamiento y métricas de evaluación apropiadas.
- Obtener al menos 3 insights relevantes, respaldados por los análisis y resultados de los modelos, relacionados con los objetivos planteados.
- Elaborar conclusiones que respondan a la pregunta de investigación, interpretando los resultados, reconociendo las limitaciones de los modelos y reflexionando sobre su aplicación profesional, utilidad para la toma de decisiones y potencial impacto en el contexto empresarial.

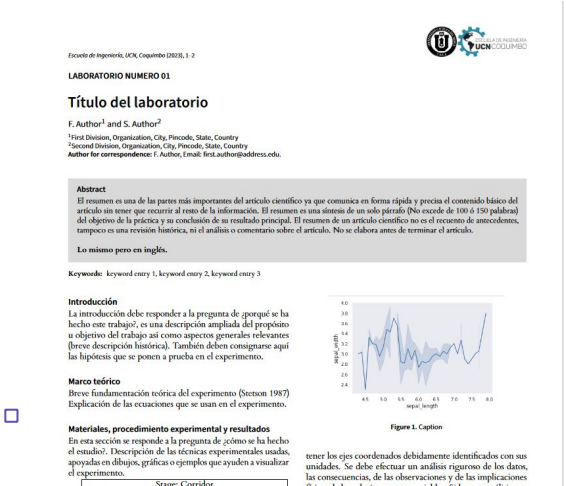
CRISP-DM



El trabajo debe ser guiado por la metodología CRISP-DM

Resumen

- **Fecha de entrega:** viernes, 20 de noviembre de 2026, 23:59
  - **Entregable:**
  - Informe de 3-6 páginas en pdf usando **formato** disponible en plataforma
  - Archivo de KNIME
  - Entregas cuyos objetivos no hayan sido revisados por los docentes tienen más posibilidades de reprobar



Escuela de Ingeniería, UCN, Coquimbo (2023), 1–2

LABORATORIO NUMERO 01

Título del laboratorio

F. Author[1] and S. Author[2]

[1]First Division, Organization, City, Pincode, State, Country
[2]Second Division, Organization, City, Pincode, State, Country
Author for correspondence: F. Author, Email: first.author@address.edu.

Abstract

El resumen es una de las partes más importantes del artículo científico ya que comunica en forma rápida y precisa el contenido básico del artículo sin tener que recurrir al resto de la información. El resumen es una síntesis de un solo párrafo (No excede de 100 ó 150 palabras) del objetivo de la práctica y su conclusión de su resultado principal. El resumen de un artículo científico no es el recuento de antecedentes, tampoco es una revisión histórica, ni el análisis o comentario sobre el artículo. No se elabora antes de terminar el artículo.

Lo mismo pero en inglés.

Keywords: keyword entry 1, keyword entry 2, keyword entry 3

Introducción

La introducción debe responder a la pregunta de ¿porqué se ha hecho este trabajo?, es una descripción ampliada del propósito u objetivo del trabajo así como aspectos generales relevantes (breve descripción histórica). También deben consignarse aquí las hipótesis que se ponen a prueba en el experimento.

Marco teórico

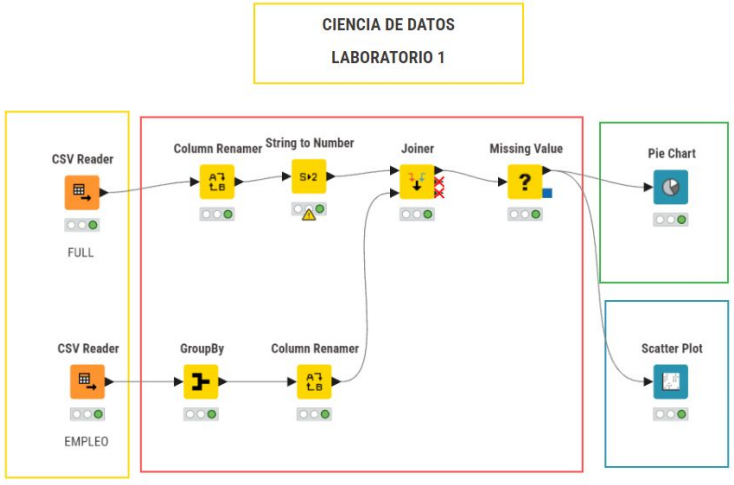
Breve fundamentación teórica del experimento (Stetson 1987) Explicación de las ecuaciones que se usan en el experimento.

Materiales, procedimiento experimental y resultados

En esta sección se responde a la pregunta de ¿cómo se ha hecho el estudio?. Descripción de las técnicas experimentales usadas, apoyadas en dibujos, gráficas o ejemplos que ayuden a visualizar el experimento.

Figure 1. Caption

tener los ejes coordenados debidamente identificados con sus unidades. Se debe efectuar un análisis riguroso de los datos, las consecuencias, de las observaciones y de las implicaciones



Evaluación

- Nota laboratorio = Informe * 0,8 + Knime * 0,2
- En el caso de haber interrogación:
  - Nota final = Nota laboratorio * 0,85 + Nota Interrogación * 0,15
- La interrogación es aprobatoria, se interroga a un estudiante del equipo determinado por el docente.

Evaluación: Consideraciones

En el caso de no utilizar el formato establecido para los informes, el equipo opta como máximo a la nota 2.0

En el caso de no subir el proyecto KNIME, opta como máximo a la nota 2.0

Evaluación: Informe

Resultado de Aprendizaje	Criterio	% Criterio	Indicador	% Indicador
Identificar los conceptos fundamentales de Data Science y su relación con otras disciplinas como matemática/estadística y aprendizaje automático.	Contextualización, estructura y síntesis del estudio	20%	Sintetizar en el abstract el problema, objetivo, método, principales resultados y conclusión del estudio.	25%
			Contextualizar el problema predictivo en su dominio, justificando su relevancia y potencial aplicación profesional.	40%
			Estructurar el desarrollo del estudio de acuerdo con las fases pertinentes de CRISP-DM.	35%
	Fundamentación conceptual y uso de fuentes	20%	Explicar los conceptos, técnicas, supuestos y métricas necesarios para comprender los modelos predictivos utilizados.	34%
			Relacionar la regresión logística con sus fundamentos matemáticos, estadísticos y de aprendizaje automático.	33%
			Respaldar las afirmaciones teóricas mediante fuentes pertinentes y confiables.	33%
Aplicar modelos básicos de análisis de datos teniendo en consideración el dominio que está siendo analizado.	Metodología de análisis y reproducibilidad	20%	Caracterizar los datos utilizados, considerando su origen, estructura, variables, volumen y calidad.	20%
			Justificar las decisiones de limpieza, preprocesamiento y transformación de los datos.	20%
			Definir y justificar la variable objetivo, las variables predictoras, la unidad de análisis y las ventanas temporales, evitando la fuga de información.	30%
			Justificar la selección, configuración y estrategia de entrenamiento y evaluación de los modelos predictivos.	20%
			Documentar el procedimiento de manera que permita reproducir los resultados obtenidos.	10%
	Presentación y trazabilidad de los resultados	20%	Presentar y comparar los resultados de los modelos predictivos mediante métricas apropiadas, vinculándolos con los objetivos del estudio.	40%
			Comunicar los resultados mediante tablas, gráficos y visualizaciones pertinentes, incluyendo el comportamiento y desempeño de los modelos.	30%
			Presentar e interpretar al menos tres hallazgos relevantes obtenidos del análisis y modelado.	20%
			Evidenciar la trazabilidad de los resultados mediante código, notebooks, anexos u otros elementos de respaldo.	10%
Interpretar los resultados obtenidos mediante modelos de análisis de datos.	Discusión, interpretación y conclusiones	20%	Interpretar los resultados y el comportamiento de los modelos en relación con el problema estudiado.	30%
			Evaluar la utilidad, limitaciones y posibles aplicaciones profesionales de los modelos desarrollados para apoyar decisiones empresariales.	30%
			Contrastar las decisiones metodológicas propias con las adoptadas por otro grupo a partir de la discusión de sus respectivos trabajos.	25%
			Sustentar las conclusiones mediante las evidencias obtenidas, respondiendo a los objetivos	15%

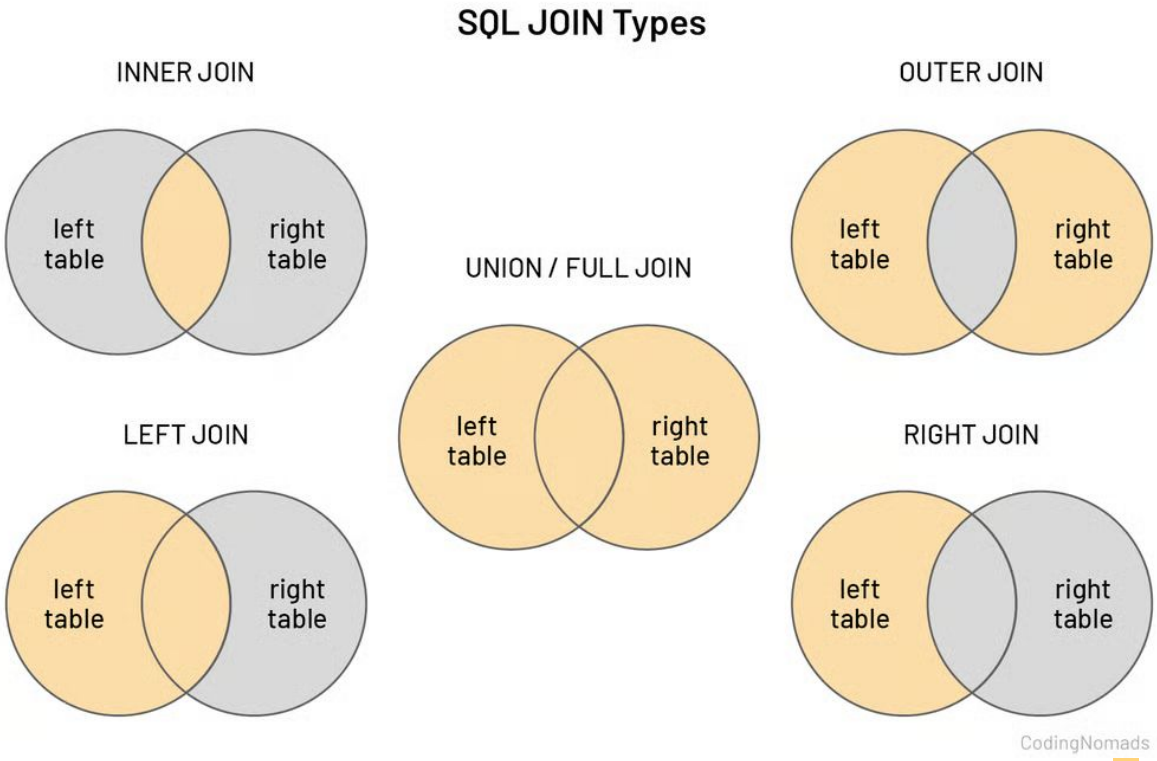
Evaluación: KNIME

Resultado de Aprendizaje	Criterio	% Criterio	Indicador	% Indicador
Aplicar modelos básicos de análisis de datos teniendo en consideración el dominio que está siendo analizado.	Integridad y funcionamiento del workflow	70%	Ejecutar los nodos esenciales del workflow en el orden previsto sin errores críticos que impidan verificar la solución.	30%
			Incorporar en el workflow las etapas exigidas por la actividad: carga, comprensión, preparación, transformación, análisis y obtención de resultados.	40%
			Mantener consistencia entre las configuraciones y salidas del workflow y la metodología aplicada en el estudio.	30%
	Organización, trazabilidad y reutilización	30%	Organizar los nodos y conexiones mediante una secuencia lógica que permita comprender el proceso desarrollado.	40%
			Documentar mediante nombres, anotaciones, metanodos o componentes las etapas y decisiones relevantes del proceso.	40%
			Configurar los recursos, rutas y parámetros de manera que el workflow pueda ser verificado por otra persona con ajustes mínimos.	20%

Evaluación: Interrogación

Resultado de Aprendizaje	Criterio	% Criterio	Indicador	% Indicador
Identificar los conceptos fundamentales de Data Science y su relación con otras disciplinas como matemática/estadística y aprendizaje automático.	Dominio conceptual, metodológico y autoría	50%	Explica los conceptos, técnicas o métricas seleccionados por el evaluador utilizando terminología pertinente al problema abordado.	33%
			Justifica decisiones específicas de la solución entregada a partir del proceso desarrollado en el laboratorio.	33%
			Responde una pregunta de precisión sobre una configuración, cálculo, etapa o alternativa implementada en la actividad.	34%
Interpretar los resultados obtenidos mediante modelos de análisis de datos.	Interpretación, argumentación y transferencia	50%	Interpreta un resultado, métrica, tabla o figura seleccionada considerando el objetivo y el dominio del estudio.	33%
			Analiza el efecto de una limitación, fuente de error, sesgo o incertidumbre presente en el trabajo realizado.	33%
			Evalúa una modificación o decisión propuesta considerando sus implicancias técnicas y su pertinencia en un contexto profesional de aplicación.	34%

Joins en SQL


SQL JOIN Types
INNER JOIN
left table
right table
OUTER JOIN
left table
right table
UNION / FULL JOIN
left table
right table
LEFT JOIN
left table
right table
RIGHT JOIN
left table
right table
CodingNomads

ESCUELA DE INGENIERÍA
UCN COQUIMBO

UNIVERSIDAD CATÓLICA DEL NORTE
CHILE

CIENCIA DE DATOS 2026 - 02

Laboratorio 02: Sistema predictivo con Regresión Logística

Docentes:
Merary Carrasco Montecino
Cristhian Rabi Reyes